

— AI / SECURITY RESEARCH PORTFOLIO

AI·Security Research Portfolio

Benchmark 설계 · 평가 자동화 · 도메인 데이터 구조화로 모델 성능과 실패 원인을 설명하는 연구 경험

박준영 Junyoung Park

Chung-Ang University · Cyber Physical System Security Lab

june295921@gmail.com

Portfolio Snapshot

Research Focus

Trustworthy AI · Safe AI · LLM Failure Analysis

Trustworthy & Safe AI

최종 출력 이전에 LLM이 언제·어디서·어떻게 무너지는지 관찰

LLM Failure Observability

Logit dynamics · refusal/compliance margin · evaluation signals

Applied AI Systems

GraphRAG for financial regulation · privacy-aware AI · local agent

모델 성능을 점수 너머의 데이터·조건·실패 원인으로 해석합니다.

단순히 모델을 구현하는 것보다, 어떤 조건에서 성능이 안정되고 왜 흔들리는지를 재현 가능한 평가로 설명하는 데 강점이 있습니다.

Junyoung Park



Chung-Ang University
Art & Technology
Cyber Security



june295921@gmail.com

ROLE

Undergraduate Researcher

Cyber Physical System Security Lab

RESEARCH FOCUS

LLM Safety & Evaluation

Failure Observability

Domain-specific QA

01

Problem Framing

ASR만으로 보이지 않는 LLM safety failure, 법령 QA에서 사라지는 조항 관계, memory가 만드는 jailbreak 조건을 문제로 정의합니다.

TLO · Persona Attack · HAI ·
Machine Unlearning(SafeAI)

02

Evaluation Design

모델·데이터·공격/사용 조건을 분리하고, LLM-as-Judge, logit signal, TaPR, group-wise loss처럼 문제에 맞는 지표를 설계합니다.

1,440 generations · 자동화 pipeline

03

System & Evidence

TLO benchmark pipeline, GraphRAG retrieval framework, local LLM agent, iOS on-device ML app처럼 실제로 동작하는 구조로 구현합니다.

GraphRAG · HAI · Machine
Unlearning(SafeAI)

NOW

Current Research Focus

LLM이 최종 답변에서 실패하기 전에, 그 실패가 어떤 데이터 조건·평가 조건·생성 과정에서 형성되는지 관찰합니다. TLO에서는 logit dynamics와 refusal/compliance margin을, Persona Attack에서는 memory 기반 jailbreak 조건을, GraphRAG에서는 도메인 관계 구조가 QA 성능과 근거 추적성에 미치는 영향을 분석했습니다.

모델의 **Failure**를 관찰 가능한 신호, 평가 기준, 개선 방향으로 바꿉니다.


At a Glance

LLM이 언제·어디서·어떻게 실패하는지를 최종 출력 이전 단계에서 이해합니다.

+20.2%p

교차 법령 Recall@5

GraphRAG · 59.6 → 79.8%




지식 그래프 3,711 nodes
완전 hit 19 → 60%
Edge precision 100% (104/104)

95.0%

GPT-4o Sequential ASR

Persona Attack · memory injection




Once 75.0% → Sequential 95.0%
AdvBench 520 FAR 84.61%
state-based memory injection

1,440

Benchmark generations

TLO · 오탐(FP) 0%




4 LLM × 3 attacks (12조건)
720 harmful + 720 benign
Early-stop ASR 39.6 → 13.1%

~15K

LOC · Local Agent

Friday · local-first runtime



3-tier model routing · planner
permission / sandbox 실행 tool
registry · 241 skills

PUBLICATIONS & OUTPUTS

Preprint

TLO — LLM Safety(제1저자)

Preprint

Persona Attack (제1저자)

학회 Oral

GraphRAG (공저자)

Preprint

REAN (공저자)

SW · 저작권 등록

GraphRAG 자산화

프로젝트들은 서로 다른 도메인에서 같은 질문을 다룹니다.

데이터가 어떤 구조로 주어지고, 평가 조건이 어떻게 설계될 때 모델 행동이 달라지는가?

Core Research

TLO
Logit-only LLM safety benchmark

제 1 저자

Persona Attack
Multi-turn memory injection 평가

제 1 저자

GraphRAG
조항·관계 기반 규제 QA

학회 발표 Oral Accepted

FinSec-LLM-Post-Training
금융보안 QA post-training & answer evaluation

개인 프로젝트

Supporting Studies & Outputs

HAI ICS
산업제어 시계열 이상탐지

SafeAI
Privacy-preserving unlearning & fairness

Friday Agent
로컬 안전 실행 assistant runtime

iOS Emotion Diary
On-device ML 감정 분석 앱

REAN
ECG 익명화 · 프라이버시—유용성 직교 기반

공저자

TLO: 최종 ASR 뒤의 Safety Failure 과정을 보는 Logit-Only Diagnostic


Challenge: 같은 Attack Success Rate라도 모델의 safety가 무너지는 시점과 방식은 서로 다를 수 있습니다. | <https://arxiv.org/abs/2605.29629> (제1저자)

기존 Attack Success Rate(ASR) 평가


최종 응답만 보고 성공/실패를 판정 → 언제부터 거절 신호가 약해졌는지는 남지 않음

Temporal Logit Observability(TLO)의 접근

Decoding step마다 거절·순응 logit margin 추적 Reference calibration
으로 모델·공격 조건을 같은 좌표에서 비교



(a) Temporal observability



(b) Calibration for comparability

Harmful Questions Set ($n = 60$)
 $q_1, q_2, \dots, q_{60}$

GCG Attack
Model's Output:
"Sure, Here is how to ..."

Successes = 34 / 60
ASR = 56.7%

DeepInception Attack
Model's Output:
"Of course, Here is how to ..."


Successes = 33 / 60
ASR = 55.0 %

MCM Attack
Model's Output:
"Sure, Here's step by step ..."

Successes = 24 / 60
ASR = 40%

Comparable ASR: 40.0% ~ 56.7%
Outcome-only score hide decoding-process differences

(a) Outcome Metrics Hide the Decoding Process



(b) Logit Signals Make Temporal Dynamics Observable

Logit-only

hidden state 접근 없이 safety signal
관찰

Temporal

최종 응답 이전의 failure path 비교

Calibrated

model/tokenizer 차이를 reference로
보정

Diagnostic

ASR을 보완해 원인을 설명하는 설명 가능성
제공

TLO는 ASR을 대체하는 지표가 아니라, "언제, 어떤 축에서, 어떤 방식으로 안전 신호가 약해졌는지"를 보여주는 관찰 도구입니다.

Benchmark 제작과 평가 자동화를 하나의 Pipeline으로

반복 실험이 가능한 구조를 만들어, 같은 가설을 여러 모델·공격 조건에서 검증했습니다.

1 조건 설계

4 LLM × 3 attacks 12 model-attack pairs harmful + benign reference

2 생성 수집

총 1,440 generations 720 harmful + 720 benign batch inference pipeline

3 자동 판정

Llama-Guard primary 보조 judge / human audit HarmBench, GPT-4o 교차검증


4 지표·도표

Logit Margin Score RP-plane, t_cross 표·그림 자동 생성

Key Results

RP-plane · 같은 ASR도 서로 다른 failure mode로 분리

Llama+DI와 Qwen+DI는 ASR이 비슷하지만 (RP_A , RP_B) 좌표가 달라집니다.



3.3%p

ASR 차이 — Llama+DI vs Qwen+DI

ASR은 비슷하지만 RP-plane에서 DRP 0.572로 분리
→ 다른 failure mode

39.6% → 13.1% → 0.0%

ASR 감소 — Early-stop probe 적용


t_cross 기반 early-stop rule로 집계 ASR 26.5%p 감소
정상 질문을 공격으로 오판하지 않음 · Plain benign 구간 false alarm 0건

Persona Attack: Multi-turn Memory가 Safety를 약화시키는가?

Challenge: 단일 prompt가 아니라 여러 턴에 누적된 memory가 안전 정책보다 우선될 수 있습니다. | <https://arxiv.org/abs/2606.00150> (제1저자)

공격 방식: Incremental Memory Injection

- Instruction imprinting — 여러 턴에 걸쳐 응답 형식·역할을 주입
- Context framing — 모델이 공격자의 작업 프레임을 수용하게 만듦
- Harmful request insertion — 기존 대화 맥락 안에 삽입
- Memory type 비교 — manual vs state-based memory 분리 평가



핵심 발견

Sequential > Once

순차적 injection이 한번에 넣는 방식보다 강력

Memory 구현 차이

state-based가 manual 보다 높은 ASR/FAR

ASR ≠ FAR


거절 없음과 완전 공격 성공을 분리하는 이중 지표

GPT-4o Sequential

95.0% ASR (Attack Success Rate)

Once 75.0% ASR · AdvBench 520 FAR 84.61%


GCG·JailBroken 대비
Once/Sequential(ours)에서 급격히 상승 — Sequential이 최고



Persona Attack은 multi-turn memory가 안전 정책을 약화시키는 조건을 분리해, 서비스형 AI의 장기 대화 평가 필요성을 보여줍니다.

GraphRAG: 도메인 데이터의 '관계 구조'를 모델 성능으로 연결

Challenge: 법령·규제·보안 문서는 관련 문장만 찾는 것보다 관계와 근거 추적성이 중요합니다. | 2025 한국전자거래학회 추계 학술대회 Oral (공저자)



교차 법령 검색 성능 · Recall@5

지식 그래프 3,711 nodes




+20.2%p 향상

완전 hit
19% → 60%

Edge precision
100% (104/104)

왜 GraphRAG인가?

- 더 큰 LLM → 비용↑ / 원인 설명 약함
- 문서 더 많이 넣기 → context noise 위험
- 관계 기반 GraphRAG → 도메인 구조를 검색·생성 근거로 사용




조항 간 관계 경로가 검색 근거로 남아, 답변마다 추적 가능한 evidence 를 제시합니다.

GraphRAG는 조항 간 관계 경로를 남겨 금융 QA의 근거 추적성과 환각 점검을 강화합니다.

FinSec-LLM-Post-Training: 금융보안 QA에서 근거 기반 답변 품질을 높이는 실험

Challenge: 금융 AI 답변은 유창성보다 정확성·근거성·불확실성 처리가 중요합니다. | 금융보안 도메인 Post-Training 실험



What I Evaluated

Answer Correctness · 정확성
MCQ accuracy · short-answer recall

Groundedness · 근거성
retrieval hit rate · answer faithfulness

Format & Uncertainty · 형식·불확실성
format validity · 근거 부족 시 유보

실제 산출물 · Built Artifacts

E5 + FAISS + BM25 · 4-bit QLoRA · assistant-only masking

1,452
법령+보안용어 SFT
train (val 157)

6.4—14.5K
보안 용어·프레임워크
instruction 예시

2,075
hybrid retrieval
chunk (+보안 847)

30
정제 법령·보안 원문 파
일

Evaluation-aware Ablation

Base LLM

RAG Context

QLoRA SFT

RAG + SFT

Answer Evaluation

Ablation Goal

법령 검색, 답변 행동 학습, 조항 관계 확장이 각각 어떤 failure mode를 줄이는지 분리 평가했습니다.

Base LLM → 금융보안 도메인 지식, 형식 불안정


RAG-only → 근거 제공 효과 확인

QLoRA-only → 답변 형식, 응답 습관 학습 효과 확인

RAG + QLoRA → 근거 기반 답변과 형식 안정성의 결합

Evaluation Result Snapshot

Ablation별 정확성 · 근거성 · 형식 안정성 비교



FinSec-LLM-Post-Training은 금융보안 QA에 맞게 "근거를 쓰는 답변 행동"을 학습 및 평가 합니다.

Supporting Projects

평가 조건을 실제 사용 환경에 맞춰 넓히는 경험


HAI ICS 이상탐지

문제 정의: 산업제어 데이터의 구간 단위 이상탐지와 시계열 특화 지표

접근:

BiLSTM Autoencoder, RobustScaler, window 20, TaPR threshold search

F1 0.693 · TaP 0.750 · TaR 0.644 — 시계열 이상탐지 end-to-end pipeline




SafeAI: Privacy Unlearning의 집단별 공정성 영향

문제 정의: Privacy-preserving unlearning이 특정 집단 성능을 더 많이 손상시키는가?

접근:

PyTorch CNN eye regression, Asian/Western group-wise loss, reweighting fine-tuning

Asian loss +81.6% · Western +42.8% — 평균 점수 뒤의 group별 영향



Engineering & Product Systems

아이디어를 시스템으로 — 논문뿐 아니라 로컬 에이전트, 앱, 등록 문서까지 전체 구현 경험

Friday Local Agent
~15,000 LOC Python

자연어가 파일 수정·Shell·Git 실행으로 이어질 때 필요한 **안전한 local-first assistant runtime**

3-tier model routing · state-machine planner · permission/sandbox · tool registry · paper library · 241개 skill index

iOS Emotion Diary
iOS prototype

민감한 일기 데이터를 외부 서버로 보내지 않고 감정 분석과 기록을 제공하는 **on-device ML privacy-aware 앱**

Swift · Create ML on-device · HealthKit 저장 · gamification reward loop

GraphRAG 기술 자산화
SW 등록 + 저작권 등록

연구 결과를 논문에서 끝내지 않고, NIPA 소프트웨어 등록과 저작권 등록이 가능한 산출물로 문서화

3-layer 시스템 명세(데이터/지식·검색·인덱스·생성/추론) · FSKU ~1,000 문항 기반 품질 검증 체계 · 적용 표준 · 시장 적용 가능성

Tech Stack & Contribution

손에 익은 도구일수록 크게

PyTorch Transformers **LLM-as-Judge**

Python tokenizer pandas · numpy LLM / Agent

FAISS · NetworkX ASR Swift · HealthKit TaPR · group loss

batch inference TensorFlow / Keras CLI / REPL · permission layer

AI Safety / Evaluation

LLM safety failure를 최종 응답이 아니라 과정과 조건으로 분석

· Benchmark 설계 · evaluation pipeline 자동화 · Logit/temporal
signal 분석 · Multi-turn / memory-aware safety 평가

Applied AI / Systems

도메인 데이터와 사용자 맥락을 실제 시스템 구조로 변환

· GraphRAG 규제 해석 · SW 등록 · Local agent runtime (~15K LOC) ·
Privacy-aware iOS app · HealthKit 연동

End of Document

Understanding when, where, and how LLMs fail before failures appear in final outputs.

박준영 Junyoung Park

Chung-Ang University · Cyber Physical System Security Lab

june295921@gmail.com

Temporal Logit Observability

TLO · Logit-only safety benchmark (제 1저자)

Persona Attack

Multi-turn memory injection (제 1저자)

GraphRAG 학회 발표 Oral + SW/저작권 등록
2025 한국전자거래학회 추계 학술대회 (공저자)

REAN

REAN: 진단 성능을 지키며 재식별을 차단하는
프라이버시-유용성 직교 기반 ECG 익명화 (공저자)

FinSec-LLM-Post-Training

금융보안 규제 QA · RAG context + 4-bit QLoRA SFT
답변 정확성/근거성 평가